

Project 2: CIFAR-10 分类与 Batch Normalization 实验报告

姓名：郭行健
学号：23300680008

代码链接：[My-own-AI-playground/deeplearning_practice/PJ2/PJ2_2026/codes at main · Gxj230958/My-own-AI-playground](https://github.com/Gxj230958/My-own-AI-playground/tree/main/Gxj230958/My-own-AI-playground)

数据集：本地使用 torchvision CIFAR-10
模型权重链接：<https://huggingface.co/Gxj230958/deeplearning-pj2>

摘要

本项目包含两部分实验。第一部分在 CIFAR-10 上设计并训练一个自定义卷积神经网络，比较卷积通道数、激活函数、损失函数正则化和优化器对分类性能的影响。第二部分基于 VGG-A 比较 Batch Normalization 前后的训练曲线，并通过不同学习率轨迹的 loss envelope、梯度变化和近似梯度 Lipschitz 曲线分析 BN 对优化 landscape 的平滑作用。

1. Train a Network on CIFAR-10

1.1 网络结构

第一题包含两类模型。第一类是从零训练的 `CifarConvNet`，用于做结构和优化策略消融；它包含 `Conv2d`、`BatchNorm2d`、激活函数、`MaxPool2d`、`Dropout` 和全连接分类层，满足题目要求的基本组件。第二类是高准确率模型：使用 ImageNet 预训练 ResNet-18，并改成 CIFAR 专用 stem，即把原来的 `7 x 7, stride=2` 首层卷积替换为 `3 x 3, stride=1`，同时移除最开始的 maxpool，避免 32x32 小图过早下采样。最后将 1000 类 ImageNet 分类头替换为 10 类 CIFAR-10 分类头，并在 CIFAR-10 上端到端微调。

1.2 优化策略

采用固定对照组，避免一次改变太多因素导致难以解释：


配置	改变因素	说明
baseline_relu32_ce_adamw	baseline	base_width=32, ReLU, CE, AdamW
wider_relu64_ce_adamw	filters	增大卷积通道数
silu32_ce_adamw	activation	将 ReLU 替换为 SiLU
relu32_label_smoothing_adamw	loss	使用 label smoothing CE
relu32_ce_l2_adamw	regularization	增大 weight decay 作为 L2 正则
relu32_ce_sgd	optimizer	使用 SGD + momentum



1.3 实验结果

高准确率模型结果：



模型	关键改动	参数量	Best Val Acc	Test Acc	Test Error	训练时间
ResNet-18 + CIFAR stem + TTA	预训练骨干、CIFAR stem、AutoAugment、RandomErasing、label smoothing、AdamW、cosine LR	11,173,962	97.26%	96.66%	3.34%	2279.1s

高准确率模型训练曲线和可解释性可视化：





PCA of Penultimate Features




从零训练的 CifarConvNet 消融结果:

配置	参数量	Best Val Acc	Test Acc	Test Error	训练时间
baseline_relu32_ce_adamw	305,258	82.42%	81.13%	18.87%	250.6 s
wider_relu64_ce_adamw	1,180,490	84.98%	83.83%	16.17%	305.8 s
silu32_ce_adamw	305,258	83.16%	82.64%	17.36%	265.9 s
relu32_label_smoothing_adamw	305,258	82.60%	81.94%	18.06%	262.4 s
relu32_ce_l2_adamw	305,258	81.88%	81.31%	18.69%	263.4 s


配置	参数量	Best Val Acc	Test Acc	Test Error	训练时间
relu32_ce_sgd	305,258	79.40%	78.49%	21.51%	275.7 s



总体对比图：



消融实验中最优从零训练模型是 wider_relu64_ce_adamw，验证集最高准确率为 84.98%，测试集准确率为 83.83%，测试错误率为 16.17%。它的训练曲线、混淆矩阵和卷积核可视化如下：

wider_relu64_ce_adamw





1.4 分析

从结果看，增大通道数是本实验中最有效的改动：base_width=64 将测试准确率从 81.13% 提升到 83.83%，但参数量也从 30.5 万增加到 118.0 万，训练时间增加约 22%。SiLU 在参数量不变的情况下达到 82.64% 测试准确率，说明更平滑的激活函数对优化有帮助，但提升小于直接增加容量。

label smoothing 的测试准确率为 81.94%，略高于 baseline，但提升不如 SiLU 和加宽网络明显；更大的 L2 正则在本设置下降低了验证和测试性能，说明 weight_decay=5e-4 对这个训练轮数和数据增强强度可能偏强。SGD + momentum 在 12 个 epoch 内只达到 78.49% 测试准确率，低于 AdamW，主要原因是没有使用更长训练或学习率调度，早期收敛速度不足。

为了进一步提升性能，高准确率模型引入了预训练和更强的数据增强。CIFAR stem 使 ResNet-18 适配 32x32 输入，避免原 ImageNet stem 过早丢失空间信息；AutoAugment、RandomErasing 和 label smoothing 提供正则化；TTA 在测试时平均原图和水平翻转图预测。最终测试准确率达到 96.66%，明显超过 95% 目标。逐类准确率图用于观察哪些类别仍然容易混淆，PCA 图显示倒数第二层特征的类别聚类情况，Grad-CAM 展示模型预测时关注的图像区域。

2. Batch Normalization

2.1 实验设置

第二题使用提供的 VGG-A 结构，并实现 VGG_A_BatchNorm。BN 版本在每个卷积层后加入 BatchNorm2d，在前两个隐藏全连接层后加入 BatchNorm1d，最终分类层保持线性输出。这样可以尽量让对比集中在 BN 对优化过程的影响。


实验设置为全量 CIFAR-10、10 epoch、batch size 64。全量训练集每个 epoch 约 $50000 / 64 = 782$ 个 step，10 epoch 约 7820 steps，和参考图横轴的 8000 steps 基本一致。

学习率列表为 [1e-4, 5e-4, 1e-3, 2e-3]。step 记录每一步训练 loss、最后分类层权重和梯度，并绘制同一步不同学习率轨迹的 loss 最小/最大包络。

2.2 VGG-A 与 VGG-A + BN 对比


模型	学习率	参数量	Best Val Acc	训练时间
VGG-A	1e-4	9,750,922	77.02%	470.8 s
VGG-A	5e-4	9,750,922	77.98%	488.5 s
VGG-A	1e-3	9,750,922	75.81%	483.3 s
VGG-A	2e-3	9,750,922	10.00%	466.8 s
VGG-A + BN	1e-4	9,754,698	74.68%	479.8 s
VGG-A + BN	5e-4	9,754,698	81.29%	433.3 s
VGG-A + BN	1e-3	9,754,698	82.91%	332.0 s
VGG-A + BN	2e-3	9,754,698	81.51%	446.9 s

训练曲线：




2.3 Loss Landscape 与梯度分析

Loss landscape envelope:




注：为了和参考图中的平滑 envelope 形状保持可比，报告主图使用未完全发散的 VGG-A 学习率轨迹绘制。

梯度变化：



近似梯度 Lipschitz 曲线：



实验中，VGG-A 在 $lr=2e-3$ 时验证准确率停留在 10%，基本等同随机猜测；而 VGG-A + BN 在相同学习率下仍能达到 81.51% 的 best val_acc。这说明 BN 显著扩大了可用学习率范围，使训练对步长更不敏感。在较合适的学习率上，BN 版本也取得更高验证精度： $lr=1e-3$ 时 VGG-A + BN 达到 82.91%，而非 BN 为 75.81%。

从 loss landscape 图看，BN 版本在不同学习率轨迹之间的 loss 包络更窄、更快下降；同时，表格中的 $lr=2e-3$ 结果显示 non-BN 会直接发散到随机猜测，而 BN 仍能稳定训练。梯度变化曲线和近似梯度 Lipschitz 曲线用于观察局部梯度是否随参数位置剧烈改变；BN 的曲线整体更适合支持“BN 通过重参数化平滑优化 landscape，使梯度方向对附近 loss 更有预测性”这一解释。

3. 结论

第一题先通过可控消融比较了网络宽度、激活函数、损失正则化和优化器，再使用 ResNet-18 + CIFAR stem 的高准确率模型将 CIFAR-10 test accuracy 提升到 96.66%，测试错误率降低到 3.34%。第二题实现并验证了 VGG-A 的 BN 版本；在约 7820 steps 的复现实验中，BN 在较大学习率下保持稳定训练，而非 BN 在 $lr=2e-3$ 时崩溃到随机水平。

参考文献

- [1] PyTorch CIFAR-10 Tutorial. https://pytorch.org/tutorials/beginner/blitz/cifar10_tutorial.html
- [2] CIFAR-10 Dataset. <https://www.cs.toronto.edu/~kriz/cifar.html>
- [3] Santurkar et al. How Does Batch Normalization Help Optimization? NeurIPS, 2018.
- [4] Krizhevsky, Hinton. Learning Multiple Layers of Features from Tiny Images. 2009.
- [5] He et al. Deep Residual Learning for Image Recognition. CVPR, 2016.